

Identificación Temprana del Riesgo Escolar: Evaluación de Modelos y Selección de Naive Bayes para Minimizar Falsos Negativos

Segunda Exposición Grupal – Taller de Programación (UBA)

Christian Campos
Alejandro Jiménez Alcocer
Julián Delgadillo Marín

Maestría en Economía Aplicada
Universidad de Buenos Aires



Miércoles 10 de diciembre de 2025

¿Por qué es importante este análisis?

- La adolescencia es una etapa especialmente vulnerable, donde se consolidan conductas de salud y bienestar escolar.
- La Encuesta Mundial de Salud Escolar (EMSE) permite identificar factores asociados al riesgo y proporciona información clave para intervenciones educativas y sanitarias.
- La detección temprana de estudiantes en riesgo crítico es fundamental para orientar acciones preventivas y el diseño de políticas públicas efectivas.
- En este contexto, el error más grave es el **falso negativo**: un estudiante que realmente está en riesgo pero el modelo no logra identificar.
- Identificar riesgo de manera anticipada permite intervenir antes de que surjan conductas problemáticas más graves.

Frase clave

“En este problema, el costo social del falso negativo es mayor que el del falso positivo; por eso toda nuestra metodología prioriza maximizar el recall.”

Objetivo del proyecto

- Construir un modelo supervisado capaz de identificar **riesgo escolar**, priorizando la **minimización de falsos negativos** como criterio central.
- Evaluar un conjunto amplio de algoritmos de clasificación (incluyendo Naive Bayes, Árboles de Decisión, Regresión Logística y otros modelos adicionales) para analizar su desempeño comparativo.
- Garantizar una evaluación justa mediante la eliminación de todas las variables que **definen directamente el criterio de riesgo** (alcohol, tabaco, lesiones y apoyo social), evitando *data leakage* y asegurando que el modelo aprenda patrones legítimos.
- Seleccionar el modelo con mejor capacidad de **detección temprana**, privilegiando simplicidad, estabilidad e interpretabilidad.

Frase breve

“Buscamos un modelo simple, estable e interpretable que maximice la detección temprana.”

Construcción de la variable de riesgo

Para el análisis se definió una variable de riesgo basada en un **score compuesto** (0–4) derivado de indicadores relevantes de la EMSE. A partir de este puntaje se construyeron dos clasificaciones:

1. Categorías originales de riesgo

- **Sin riesgo:** score = 0 (15.9 %)
- **Riesgo moderado:** score = 1–2 (81.1 % en conjunto)
- **Riesgo alto:** score = 3–4 (2.2 %)


2. Variable objetivo binaria (*Riesgo_global*)

Se consolidó una variable binaria para el modelado:

- **0 = Sin riesgo** (55.5 %)
- **1 = Con riesgo** (moderado + alto) (44.5 %)

- La binarización prioriza la **detección temprana**, incluyendo casos moderados dentro de la categoría de riesgo para evitar falsos negativos estratégicos.

Curvas ROC — Comparación Completa de Modelos



- Las curvas ROC muestran desempeños **similares** entre la mayoría de los modelos (AUC 0.64–0.66).
- Random Forest, Gradient Boosting y modelos lineales presentan las mejores AUC.
- Naive Bayes muestra un AUC competitivo ($\approx 0,643$).
- AUC no refleja el costo de errores $\rightarrow$ lo central es **minimizar falsos negativos**.


Comparación de Modelos según TP, FP, TN y FN

Modelo	TP	FP	TN	FN
Naive Bayes	4407	3526	5962	3200
Árbol podado	4262	3184	6304	3345
HistGradientBoosting (rápido)	4062	2897	6591	3545
HistGradientBoosting (XGBoost)	4062	2897	6591	3545
Random Forest (rápido)	3934	2827	6661	3673
LASSO	3824	2643	6845	3783
Logit	3785	2615	6873	3822
Ridge	3785	2615	6873	3822
SVM lineal	3774	2610	6878	3833
KNN (k=10)	3115	2615	6873	4492

Cuadro: Tabla comparativa de aciertos y errores por modelo. El criterio principal es minimizar los falsos negativos (FN).

- El **menor número de falsos negativos (FN)** corresponde a **Naive Bayes (3200)**.
- Este criterio es crucial: un FN implica un estudiante en riesgo real no detectado.
- Por este motivo, Naive Bayes es seleccionado como el **modelo óptimo para detección temprana**.

Comparación de Modelos: Naive Bayes, Árbol Podado y Logit



- Los tres modelos presentan desempeños similares en términos generales.
- Sin embargo, tanto Árbol podado como Logit mantienen **más de 3300–3800 falsos negativos**.
- Naive Bayes reduce este valor a **3009 FN**, siendo el más efectivo para **detección temprana de riesgo crítico**.
- Para nuestro objetivo —*minimizar falsos negativos*— Naive Bayes resulta claramente superior.


Evaluación del Modelo Elegido: Naive Bayes

Matriz de Confusión - Modelo Ganador: Naive Bayes

Valor Real	Predicción	
	No Riesgo	Riesgo
No Riesgo	TN = 5907	FP = 3581
Riesgo	FN = 3009	TP = 4598

Matriz de Confusión

Top 10 Variables Más Importantes – Naive Bayes




Top 10 Variables Más Importantes

- Naive Bayes obtiene el **menor número de falsos negativos (FN = 3009)**, cumpliendo el criterio principal del proyecto.
- El modelo logra un balance adecuado entre sensibilidad y simplicidad, favoreciendo su estabilidad.
- Las variables **Sexo**, **Actividad física** y **Edad** emergen como señales clave en la predicción del riesgo crítico.


Árbol de Decisión Podado — Interpretación del Modelo

Árbol de decisión podado – EMSE 18



- Se entrenó un árbol de decisión y se aplicó **poda de complejidad mínima (ccp_alpha)** para evitar sobreajuste.
- El árbol revela patrones consistentes con los hallazgos anteriores:
 - La variable **Sexo** aparece como primer separador.
 - La **actividad física** es un predictor clave a lo largo del árbol.
 - La **edad** (13–15 años) segmenta grupos con riesgo diferenciado.
- Aunque interpretable, el árbol mantiene un número alto de **falsos negativos**, por lo que no fue seleccionado como modelo óptimo.

Importancia de Variables — Árbol de Decisión Podado



- El árbol podado identifica variables clave que explican la segmentación del riesgo.
- **Edad 13 años** y **Sexo Masculino** aparecen como los predictores más influyentes.
- La **actividad física (Nunca)** y la **edad 14 años** también contribuyen fuertemente a la clasificación.
- Confirma patrones observados en otros modelos: factores demográficos y de comportamiento explican gran parte del riesgo.

Conclusiones Generales

- Es importante destacar que se eliminaron del conjunto de predictores todas las variables que definían directamente el criterio de riesgo (Alcohol, Tabaco, Lesiones, Amigos cercanos) para evitar *data leakage*. Esto explica que las variables más importantes del modelo final correspondan a factores indirectos como Sexo, Edad y Actividad física.
- El análisis comparativo de múltiples modelos supervisados evidenció que, aunque varios presentan desempeños similares en métricas globales, el **número de falsos negativos (FN)** es el criterio decisivo para este proyecto.
- **Naive Bayes** se posicionó como el modelo óptimo al obtener el **menor FN (3009)**, garantizando una mayor detección de estudiantes en riesgo crítico.
- Los modelos lineales (Logit, Ridge y LASSO) mostraron estabilidad, pero sus niveles elevados de FN los hacen menos adecuados para el objetivo principal.
- La interpretabilidad fue clave: tanto el árbol podado como la importancia de variables revelaron que **Sexo, Actividad física y Edad** son factores determinantes en la clasificación del riesgo.
- El modelo final proporciona una base sólida para la **detección temprana**, con potencial para integrarse en sistemas reales de apoyo académico.