

Universidad de Buenos Aires  
Facultad de Ciencias Económicas  
Escuela de Estudios de Posgrado

Clasificación de Hogares Pobres en la EPH (2025): Regularización,  
Árboles de Decisión y Comparación de Métodos Predictivos

Trabajo Práctico N°4 - Grupo 15

DOCENTE: NOELIA ROMERO

ASIGNATURA: TALLER DE PROGRAMACIÓN

Repositorio GitHub - Grupo 15

INTEGRANTES: CHRISTIAN CAMPOS, ALEJANDRO ALCOCER, JULIÁN DELGADILLO MARÍN

POSGRADO: MAESTRÍA EN ECONOMÍA APLICADA

Fecha de Entrega: Viernes 28 de Noviembre de 2025

Resumen

El presente informe aplica métodos de regularización (LASSO y Ridge) y árboles de decisión a la EPH 2025 con el objetivo de predecir la condición de pobreza. A partir de las bases construidas en el TP3, se estimaron modelos de regresión logística penalizada utilizando una grilla de valores  $\lambda = 10^n$  con  $n \in [-5, 5]$ , analizando las trayectorias de coeficientes y seleccionando la penalidad óptima mediante validación cruzada de 5 folds. Con los valores  $\lambda^{cv}$  se compararon los coeficientes del logit sin penalidad, LASSO y Ridge, destacando la capacidad de LASSO para anular predictores y la contracción más homogénea inducida por Ridge.

Asimismo, se estimó un árbol de decisión (CART) podado mediante validación cruzada de 10 folds, evaluando el error de clasificación para distintos niveles de complejidad y presentando tanto el árbol resultante como la importancia de los predictores. La comparación entre productos de regularización y CART permitió analizar la consistencia en la selección de variables y el aporte de relaciones no lineales.

Finalmente, el desempeño de todos los modelos—incluidos logit y KNN del TP3—se evaluó mediante matrices de confusión, curvas ROC y métricas de clasificación. Los resultados evidencian diferencias en el trade-off entre interpretabilidad y capacidad predictiva, relevantes para la identificación de hogares vulnerables en el marco de programas públicos de asignación de recursos.

**Palabras clave:** regularización, LASSO, Ridge, árboles de decisión, clasificación, EPH, pobreza.

El análisis inicial de las bases utilizadas se resume en los Cuadros 1 y 2. El Cuadro 1 muestra que la EPH 2025 fue dividida en un conjunto de entrenamiento con 3,016 observaciones y diez predictores, y un conjunto de prueba con 1,293 observaciones con la misma dimensionalidad. El vector objetivo  $y$ , correspondiente a la condición de pobreza, se mantuvo como una única columna en ambas particiones. Esta separación permite calibrar los modelos (Logit, LASSO, Ridge y CART) sobre datos que contienen suficiente variabilidad y, simultáneamente, evaluar su capacidad de generalización en muestras no utilizadas durante el entrenamiento. Por su parte, el Cuadro 2 resume la estructura empleada para la estimación penalizada: se trabajó con diez predictores y una grilla de once valores de penalidad definida como  $\lambda = 10^n$ , con  $n \in \{-5, -4, \dots, 4, 5\}$ . La estimación generó matrices de coeficientes de dimensión  $11 \times 10$ , donde cada fila corresponde a un valor de  $\lambda$  y cada columna a un predictor, constituyendo la base para el análisis de las trayectorias de regularización que permiten estudiar la contracción o anulación de parámetros según la magnitud de la penalidad.

Cuadro 1. Dimensiones de las bases de entrenamiento y prueba (año 2025)

| Conjunto       | Número de observaciones | Número de variables |
|----------------|-------------------------|---------------------|
| X_train (2025) | 3016                    | 10                  |
| X_test (2025)  | 1293                    | 10                  |
| y_train (2025) | 3016                    | 1                   |
| y_test (2025)  | 1293                    | 1                   |


Cuadro 2. Dimensiones de los coeficientes estimados para LASSO y Ridge

| Concepto                          | Valor    | Descripción                                  |
|-----------------------------------|----------|----------------------------------------------|
| Shape coeficientes Ridge          | (11, 10) | 11 penalidades $\lambda \times 10$ variables |
| Shape coeficientes LASSO          | (11, 10) | 11 penalidades $\lambda \times 10$ variables |
| Cantidad de penalidades $\lambda$ | 11       | Grilla: $10^n$ con $n \in [-5, 5]$           |
| Cantidad de variables             | 10       | Predictores utilizados en X_train            |

**Cuadro 3.** Cantidad de coeficientes exactamente cero en LASSO según el valor de  $\lambda$

| $\lambda$          | Coeficientes en cero | Proporción (de 10 variables) |
|--------------------|----------------------|------------------------------|
| $1 \times 10^{-5}$ | 0                    | 0.00                         |
| $1 \times 10^{-4}$ | 0                    | 0.00                         |
| $1 \times 10^{-3}$ | 0                    | 0.00                         |
| $1 \times 10^{-2}$ | 0                    | 0.00                         |
| $1 \times 10^{-1}$ | 0                    | 0.00                         |
| 1                  | 2                    | 0.20                         |
| 10                 | 2                    | 0.20                         |
| 100                | 5                    | 0.50                         |
| 1000               | 8                    | 0.80                         |
| 10000              | 9                    | 0.90                         |
| 100000             | 9                    | 0.90                         |

En el Cuadro 3 podemos ver que el modelo LASSO muestra un patrón claro de selección de variables a medida que aumenta la penalización. Para valores pequeños de  $\lambda$  los coeficientes no se reducen a cero, lo que implica que el modelo incluye la totalidad de los predictores. A partir de  $\lambda = 1$ , el LASSO comienza a anular coeficientes, eliminando dos variables. Para valores intermedios como  $\lambda = 100$ , la mitad de los coeficientes se reducen a cero, y para penalizaciones muy grandes ( $\lambda \geq 1000$ ), el modelo deja activas solamente una o dos variables. Este comportamiento es consistente con la lógica del LASSO, que realiza selección automática al forzar a cero coeficientes considerados irrelevantes por el modelo.



**Figura 1.** Evolución de los coeficientes bajo penalización Ridge (L2) y LASSO (L1) para distintos valores de  $\lambda$ .

La **Figura 1** muestra la evolución de los coeficientes estimados bajo penalización Ridge (L2) y LASSO (L1) para una grilla de once valores de  $\lambda$ , distribuidos logarítmicamente entre  $10^{-5}$  y  $10^5$ . Se observa un comportamiento marcadamente distinto entre ambas regularizaciones.

En el caso de Ridge (panel izquierdo), los coeficientes se reducen suavemente hacia cero a medida que crece  $\lambda$ , pero ninguno de ellos se vuelve exactamente igual a cero. Esto es consistente con la naturaleza de la penalización L2, que contrae los coeficientes manteniendo todas las variables en el modelo.

En cambio, con LASSO (panel derecho) los coeficientes experimentan una contracción más abrupta. A partir de valores intermedios de la penalización, varios coeficientes se reducen exactamente a cero, lo que evidencia la capacidad del LASSO para realizar selección automática de variables. Para penalizaciones altas ( $\lambda \geq 100$ ), el modelo retiene únicamente un subconjunto muy pequeño de predictores.

A partir de la validación cruzada con cinco particiones, el valor óptimo de la penalización para el modelo Ridge resultó ser  $\lambda_{cv} = 1 \times 10^{-5}$ . Este valor corresponde al hiperparámetro que minimiza el error de clasificación promedio entre folds. Dado que en la regresión logística de `sklearn` el parámetro de penalización se controla mediante  $C = 1/\lambda$ , el valor óptimo encontrado implica un  $C$  elevado, lo que refleja un nivel de regularización muy bajo. En términos prácticos, el modelo Ridge selecciona una penalización mínima, privilegiando mantener coeficientes cercanos a los estimados sin regularización.

**Cuadro 4.** Penalidad óptima seleccionada por validación cruzada para Ridge

| Método     | Valor óptimo $\lambda_{cv}$ |
|------------|-----------------------------|
| Ridge (L2) | $1 \times 10^{-5}$          |


El hecho de que la validación cruzada seleccione como se puede ver en el Cuadro 4 un  $\lambda$  extremadamente pequeño indica que el modelo no requiere una regularización fuerte para mejorar su desempeño. En consecuencia, Ridge no elimina variables ni contrae significativamente los coeficientes, lo cual es consistente con el comportamiento observado en la **Figura 1**, donde la magnitud de los coeficientes permanece casi constante para toda la grilla de  $\lambda$ .

En el caso de la penalización L1 (LASSO), la validación cruzada con cinco particiones seleccionó como valor óptimo  $\lambda_{cv} = 10$ . Este valor corresponde al hiperparámetro que minimizó el error de clasificación promedio en los folds. Dado que en la implementación utilizada se cumple que  $C = 1/\lambda$ , esto implica que el mejor modelo LASSO fue aquel con un nivel moderado de regularización.

**Cuadro 5.** Penalidad óptima seleccionada por validación cruzada para cada modelo

| Método     | $\lambda_{cv}$     | Interpretación                                  |
|------------|--------------------|-------------------------------------------------|
| Ridge (L2) | $1 \times 10^{-5}$ | Regularización casi nula                        |
| LASSO (L1) | 10                 | Regularización moderada, selección de variables |


El contraste entre ambos resultados mostrado en el Cuadro 5 es consistente con el comportamiento esperado de cada penalización. Mientras que Ridge selecciona un  $\lambda$  extremadamente pequeño, lo que equivale a una regularización mínima y a mantener prácticamente todos los coeficientes en el modelo, LASSO elige una penalización sustancialmente mayor ( $\lambda = 10$ ). Este nivel de regularización provoca que LASSO reduzca varios coeficientes exactamente a cero, tal como se observó en el análisis previo, realizando un proceso de selección automática de variables.



**Figura 2.** Error de clasificación promedio para distintos valores de  $\lambda$  bajo penalización Ridge (L2) y LASSO (L1), utilizando validación cruzada de 5 particiones.

La **Figura 2** muestra el error de clasificación promedio asociado a cada valor de  $\lambda$  en la grilla evaluada. En el caso de Ridge, el error mínimo se alcanza para  $\lambda = 10^{-5}$ , valor que coincide con el seleccionado por validación cruzada. Para valores de penalización mayores, el desempeño se deteriora de manera pronunciada, lo cual indica que una regularización excesiva perjudica la capacidad predictiva del modelo.

En el caso de LASSO, el error mínimo se obtiene alrededor de  $\lambda = 10$ , coherente con el resultado arrojado por la validación cruzada. Para valores grandes de penalización, el error aumenta debido a que el LASSO elimina una proporción creciente de variables, reduciendo en exceso la complejidad del modelo. Este comportamiento es consistente con la interpretación previa sobre selección de variables.



**Figura 3.** Proporción de coeficientes en cero para distintos valores de  $\lambda$  en el modelo LASSO.

La **Figura 3** muestra claramente el efecto de la penalización L1 sobre la selección de variables. Para valores pequeños de  $\lambda$  (entre  $10^{-5}$  y  $10^{-2}$ ), el LASSO no elimina ninguna variable y todos los coeficientes permanecen activos. A partir de  $\lambda = 1$ , comienza a anular coeficientes y alrededor de la mitad de las variables son eliminadas para  $\lambda = 100$ . Para valores mayores ( $\lambda \geq 10^3$ ), el modelo descarta entre el 80 % y el 90 % de los predictores.

Este comportamiento es coherente con la naturaleza del LASSO, que introduce esparsidad en los coeficientes y funciona como un mecanismo de selección automática de variables. La mayor parte de la reducción ocurre de manera abrupta entre  $\lambda = 10$  y  $\lambda = 1000$ , lo que coincide con el punto donde la penalización comienza a dominar sobre el término de verosimilitud.


**Cuadro 6.** Comparación de coeficientes estimados: Logit sin penalidad, LASSO y Ridge

| Variable       | Sin penalidad | L1 (LASSO) | L2 (Ridge)  |
|----------------|---------------|------------|-------------|
| ch04           | 0.270796      | 0.139089   | 0.273181    |
| ch06           | -0.0137086    | -0.013544  | -0.013688   |
| nivel_ed       | -0.180242     | -0.172740  | -0.1804287  |
| region         | $\approx 0$   | 0          | $\approx 0$ |
| aglomerado     | 0.765242      | 0.423378   | 0.770603    |
| cat_ocup       | 0.0512319     | 0.005632   | 0.051098    |
| cat_inac       | 0.1377427     | 0.114025   | 0.137830    |
| ad_equiv_hogar | 0.384959      | 0.378984   | 0.383529    |
| cbt_equiv      | -0.0729393    | -0.000041  | -0.073492   |
| const          | $\approx 0$   | 0          | $\approx 0$ |

El Cuadro 6 presenta los coeficientes estimados para cada especificación. En el modelo sin penalización, todas las variables permanecen activas. En el caso del LASSO, algunos coeficientes son reducidos exactamente a cero (por ejemplo, **region** y **const**), lo que evidencia la capacidad de la penalización L1 para realizar selección automática de variables. Por el contrario, la penalización Ridge no lleva coeficientes exactamente a cero, sino que simplemente contrae su magnitud de manera suave. En general, los coeficientes de Ridge permanecen cercanos a los del modelo sin penalidad, lo cual coincide con el hecho de que la validación cruzada seleccionó una penalización muy baja ( $\lambda_{cv} = 10^{-5}$ ).



A medida que se avanza hacia los nodos terminales, se observan reglas de decisión más específicas que combinan predictores socioeconómicos y demográficos. El árbol podado mantiene una estructura comprensible e interpretativamente útil, lo que constituye una ventaja frente a modelos más complejos como LASSO o Ridge. No obstante, su desempeño predictivo puede ser inferior, lo cual se discute en la sección de comparación final.



**Figura 6.** Importancia de variables en el árbol de decisión podado utilizando el valor óptimo de *ccp\_alpha*.

La **Figura 6** muestra la importancia relativa de los predictores en el árbol de decisión podado. La variable con mayor peso es **ad\_equiv\_hogar**, que concentra más del 50 % de la importancia total del modelo. Esto sugiere que el ingreso equivalente del hogar es el factor más determinante para la clasificación de la condición de pobreza en la muestra analizada.


Otros predictores relevantes incluyen **ch06** (edad del jefe del hogar), **nivel\_ed** (nivel educativo) y **cat\_inac** (categoría de inactividad). Estas variables reflejan componentes demográficos y laborales que inciden fuertemente en la vulnerabilidad socioeconómica.

En contraste, variables como **region**, **cbt\_equiv** y la constante presentan importancia nula o muy baja, lo cual indica que el árbol podado no las considera informativas para segmentar a la población en términos de pobreza. En conjunto, la distribución de importancia es coherente con la estructura del árbol presentada en el punto B.5 y con los patrones observados previamente en los modelos de regresión penalizada.

**Cuadro 7.** Importancia de variables en el árbol de decisión podado

| Variable       | Importancia |
|----------------|-------------|
| ad_equiv_hogar | 0.583031    |
| ch06           | 0.123364    |
| nivel_ed       | 0.119206    |
| cat_inac       | 0.069723    |
| aglomerado     | 0.059540    |
| cat_ocup       | 0.028672    |
| ch04           | 0.016465    |
| region         | 0.000000    |
| cbt_equiv      | 0.000000    |
| const          | 0.000000    |

El Cuadro 7 confirma los patrones observados en la **Figura 6**. La variable **ad\_equiv\_hogar** concentra más del 58 % de la importancia total del árbol podado, lo que la convierte en el predictor dominante para la clasificación de pobreza. Otros predictores relevantes, aunque con menor peso, son **ch06**, **nivel\_ed** y **cat\_inac**. En contraste, variables como **region**, **cbt\_equiv** y la constante no aportan información al modelo, lo que refleja su escaso valor predictivo para las reglas de decisión del árbol podado.



**Figura 7.** Curvas ROC de los modelos estimados: logit sin penalidad, LASSO, Ridge, árbol podado y KNN ( $K = 10$ ).

La **Figura 7** compara las curvas ROC de los distintos modelos estimados. Se observa que todos los métodos presentan un desempeño similar, con áreas bajo la curva (AUC) cercanas a 0.79, lo que indica un nivel moderado de capacidad predictiva. El logit sin penalización, Ridge y el árbol podado presentan prácticamente el mismo AUC ( $=0.790$ ), mientras que el LASSO muestra un valor levemente inferior ( $=0.788$ ) y el KNN con  $K = 10$  alcanza el menor AUC del conjunto ( $=0.782$ ).

La proximidad entre las curvas sugiere que ninguno de los métodos presenta mejoras sustanciales en términos de la relación entre verdaderos positivos y falsos positivos. Esto refuerza la idea de que, en este caso, la complejidad o la estructura del modelo (lineal penalizado, no penalizado, árbol o KNN) no genera diferencias marcadas en la capacidad discriminatoria.

**Cuadro 8.** Matrices de confusión para cada modelo (Test 2025)

| Modelo              | TN  | FP | FN  | TP  |
|---------------------|-----|----|-----|-----|
| Logit sin penalidad | 820 | 83 | 249 | 141 |
| LASSO (L1)          | 827 | 76 | 255 | 135 |
| Ridge (L2)          | 820 | 83 | 250 | 140 |
| Árbol podado        | 815 | 88 | 246 | 144 |
| KNN (K=10)          | 827 | 76 | 258 | 132 |

El Cuadro 8 resume las matrices de confusión de los distintos modelos. Se observa que los modelos lineales (logit sin penalidad, LASSO y Ridge) presentan un comportamiento muy similar, con diferencias menores en los falsos positivos y falsos negativos. El árbol podado muestra un número ligeramente mayor de verdaderos positivos ( $TP = 144$ ), lo cual incrementa su sensibilidad. En cambio, KNN presenta la mayor cantidad de falsos negativos ( $FN = 258$ ), lo que implica que clasifica incorrectamente a más hogares pobres como no pobres, lo cual es problemático para políticas públicas.

### C.7 Elección del mejor modelo para asignar recursos públicos

En el TP3 se había concluido que KNN era el modelo más adecuado para una política pública de focalización, principalmente porque presentaba la mayor sensibilidad (recall) y, por lo tanto, dejaba fuera a un menor número de hogares pobres. Sin embargo, los resultados del TP4 modifican esta recomendación.

El Cuadro 8 muestra que, al comparar los falsos negativos (FN), el modelo KNN es el que más hogares pobres excluye: 258 casos. Por el contrario, el árbol de decisión podado es el modelo que logra el menor número de FN (246), seguido muy de cerca por el logit sin penalidad (249). Los modelos penalizados presentan un desempeño inferior en este aspecto (250–255 FN).

Dado que el objetivo del Ministerio de Capital Humano es minimizar la exclusión de hogares vulnerables, el criterio central de evaluación debe ser la reducción de falsos negativos. Además, los valores de AUC son muy similares entre todos los métodos (aprox. 0.78–0.79), por lo que las diferencias en desempeño discriminatorio no son estadísticamente relevantes.

En este contexto, el árbol podado se posiciona como el modelo más adecuado para la asignación de recursos escasos, ya que:

1. Minimiza la cantidad de hogares pobres clasificados erróneamente como no pobres;

2. Ofrece una estructura interpretable basada en reglas de decisión, valiosa para justificar la política pública ante organismos de control;
3. Es consistente con el principio de precaución social: es preferible otorgar ayuda a un hogar no pobre que excluir por error a un hogar vulnerable.

**Conclusión.** A diferencia del TP3, donde KNN aparecía como el modelo más sensible, la evidencia del TP4 muestra que el árbol podado es el mejor modelo para orientar políticas públicas de asistencia. Minimiza los falsos negativos, mantiene un desempeño global comparable al de los demás modelos y presenta una estructura transparente que facilita su interpretación y comunicación. En políticas sociales, donde el criterio central es no excluir hogares necesitados, el árbol podado constituye la opción más robusta y adecuada para la toma de decisiones.